

174- [JAWS] - Lab - Escalado y equilibrio de carga de una arquitectura

Datos Generales:

Nombre: Tomás Alfredo Villaseca Constantinescu

País: Chile

Fecha: 21/10/2023

Contacto: tomas.villaseca.c@gmail.com

Después de completar este laboratorio, usted podrá ser capaz de hacer lo siguiente:

- Crear una AMI a partir de una instancia EC2.
- Crear un equilibrador de carga.
- Crear una plantilla de lanzamiento y un grupo de Auto Scaling.
- Configurar un grupo de Auto Scaling para escalar nuevas instancias dentro de subredes privadas.
- Utilizar las alarmas de Amazon CloudWatch para monitorizar el rendimiento de la infraestructura.

Resumen Laboratorio:

En este laboratorio, utilizará Elastic Load Balancing (ELB) y Amazon EC2 Auto Scaling para equilibrar la carga y escalar automáticamente su infraestructura.

ELB distribuye automáticamente el tráfico entrante de las aplicaciones entre varias instancias de Amazon EC2.

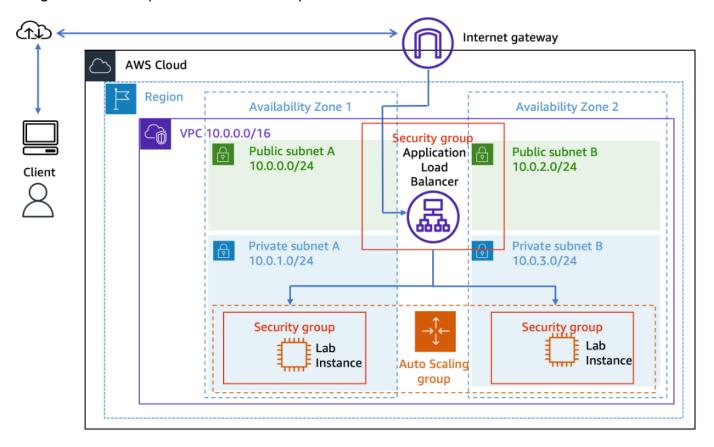
ELB proporciona la cantidad de capacidad de equilibrio de carga necesaria para enrutar el tráfico de las aplicaciones con el fin de conseguir tolerancia a fallos en sus aplicaciones.

Auto Scaling le ayuda a mantener la disponibilidad de las aplicaciones y le ofrece la posibilidad de reducir o aumentar automáticamente la capacidad de Amazon EC2 en función de las condiciones que defina.

Puede utilizar el escalado automático para asegurarse de que está ejecutando el número deseado de instancias EC2.

El escalado automático también puede aumentar automáticamente el número de instancias EC2 durante picos de demanda para mantener el rendimiento y puede reducir la capacidad durante periodos de inactividad para reducir costes.

Diagrama de la arquitectura final al completar el laboratorio:

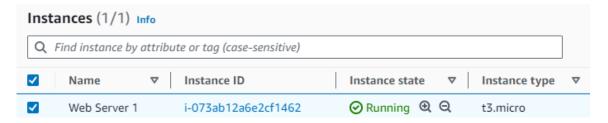


Tarea 1: Crear una AMI

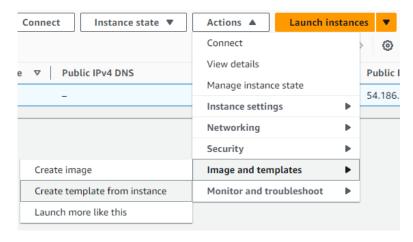
para Auto Scaling

En esta tarea, se crea una AMI a partir del Web Server 1 existente. Esta acción guarda el contenido del boot disk para que se puedan lanzar nuevas instancias con idéntico contenido.

Paso 1: AWS Management Console → Search → EC2 → Instances → Web Server 1



Paso 2: Web Server 1 → Actions → Image and templates → Create image



Paso 3: Create Image

- Image name = Web Server AMI
- Image description = Lab AMI for Web Server

Instance ID

i-073ab12a6e2cf1462 (Web Server 1)

Image name

Web Server AMI

Maximum 127 characters. Can't be modified after creation.

Image description - optional

Lab AMI for Web Server

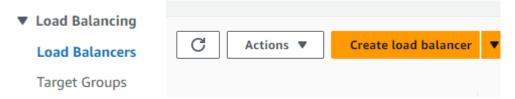
Maximum 255 characters

Tarea 2: Crear un

balanceador de carga

En esta tarea, se crea un equilibrador de carga que puede equilibrar el tráfico entre varias instancias EC2 y zonas de disponibilidad.

Paso 1: EC2 → Panel de navegación → Load Balancing → Load Balancers → Create Load Balancer



Paso 2: Create Load Balancer → Load Balancer types

Application Load Balancer → Create

Load balancer types						
Application Load Balancer Info	Network Load Balancer Info	Gateway Load Balancer Info				

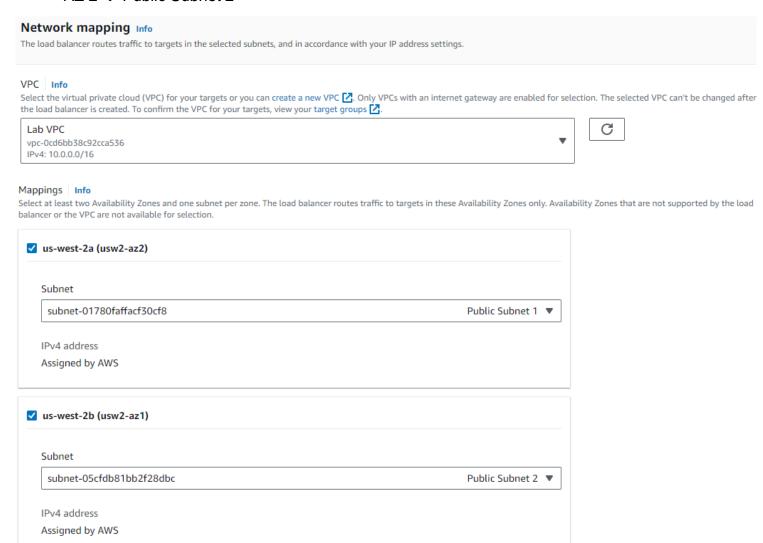
Paso 3: Create Application Load Balancer → Basic Configuration

Load Balancer Name = LabELB

Load balancer name Name must be unique within your AWS account and can't be changed after the load balancer is created. LabELB A maximum of 32 alphanumeric characters including hyphens are allowed, but the name must not begin or end with a hyphen. Scheme Info Scheme can't be changed after the load balancer is created. Internet-facing An internet-facing load balancer routes requests from clients over the internet to targets. Requires a public subnet. Learn more Internal An internal load balancer routes requests from clients to targets using private IP addresses. IP address type Info Select the type of IP addresses that your subnets use. IPv4 Recommended for internal load balancers. Dualstack Includes IPv4 and IPv6 addresses.

Paso 4: Create Application Load Balancer → Network mapping

- VPC → Lab VPC
- Mappings → Seleccionar las dos AZs listadas.
- AZ 1 → Public Subnet 1
- AZ 2 → Public Subnet 2



Estas opciones configuran el equilibrador de carga para que funcione en varias zonas de disponibilidad.

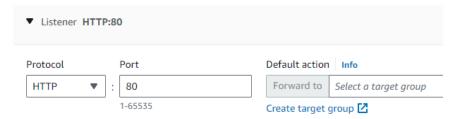
Paso 5: Create Application Load Balancer → Security Groups

Desplegar lista → Web Security Group (permite conexión HTTP)

Security groups Select up to 5 security groups Web Security Group sg-07a905745150be2a4 VPC: vpc-0cd6bb38c92cca536

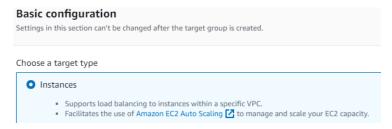
Paso 6: Create Application Load Balancer → Listeners and routing

Create target group → Se abre una nueva pestaña en el navegador.



Paso 7: Target groups → Basic configuration

Choose target type → Instances



Target group name = lab-target-group

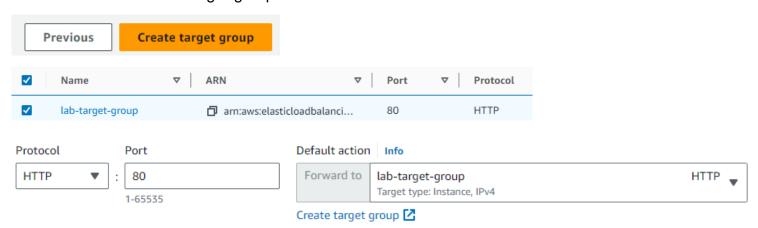
Target group name

lab-target-group

A maximum of 32 alphanumeric characters including hyphens are allowed, but the name must not begin or end with a hyphen.

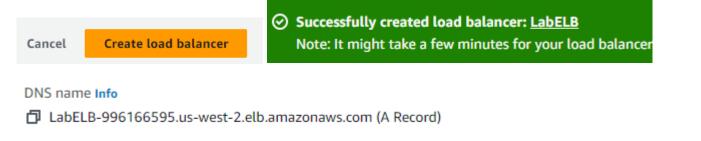
Paso 8: Target groups → Register targets → Create target group

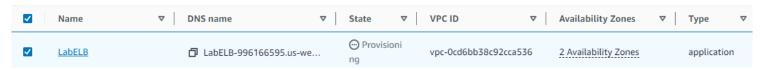
- Volver a la pestaña de Load Balancers
- Refrescar la sección Listeners and routing.
- Forward to → lab-target-group



Paso 9: Create Application Load Balancer → Create Load Balancer

- View Load Balancer
- Copiar el DNS name de LabELB → LabELB-996166595.us-west-2.elb.amazonaws.com





Tarea 3: Crear una plantilla de lanzamiento

En esta tarea, se creará una plantilla de lanzamiento (launch template) para el grupo de Auto Scaling.

Una plantilla de lanzamiento es una plantilla que un grupo de Auto Scaling utiliza para lanzar instancias EC2.

Al crear una plantilla de lanzamiento, se especifica información para las instancias, como la AMI, el tipo de instancia, el par de claves, el grupo de seguridad y los discos.

Paso 1: EC2 → Instances → Launch Templates → Create Launch Template

▼ Instances
 Instances
 Instance Types
 Launch Templates
 Spot Requests

Create launch template

Paso 2: Create Launch Template → Launch template name and description

- Launch template name = lab-app-launch-template
- Template version description = a web server for the load test app
- Auto scaling guidance → Seleccionar casilla "Provide guidance to help me set up a template that I can use with EC2 Auto Scaling".

Launch template name and description

Launch template name - required

lab-app-launch-template

Must be unique to this account. Max 128 chars. No spaces or special characters like '&', '*', '@'.

Template version description

a web server for the load test app

Max 255 chars

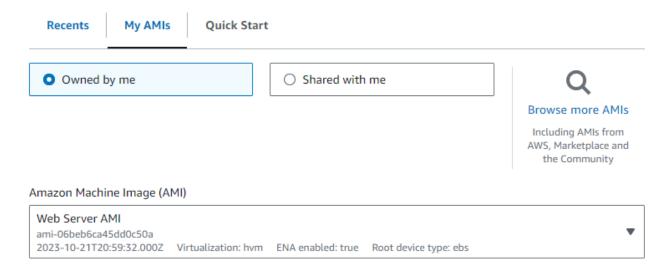
Auto Scaling guidance Info

Select this if you intend to use this template with EC2 Auto Scaling

Provide guidance to help me set up a template that I can use with EC2 Auto Scaling

Paso 3: Create Launch Template → Application and OS Images

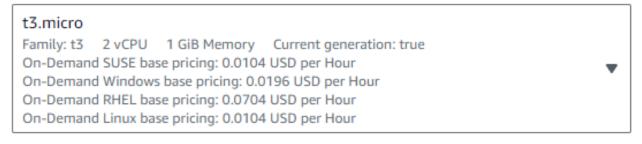
My AMIs → Web Server AMI



Paso 4: Create Launch Template → Instance type

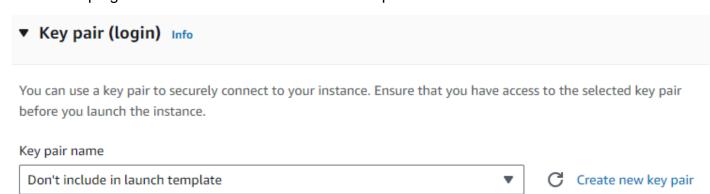
Desplegar lista → t3.micro

Instance type



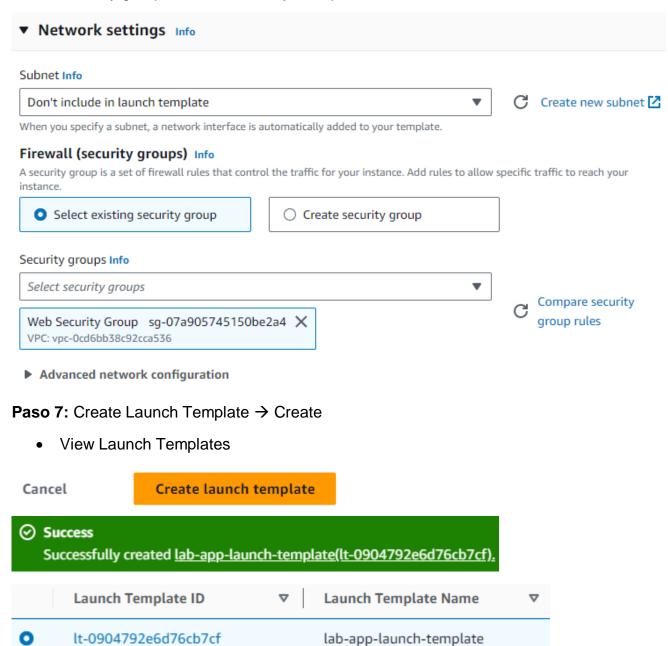
Paso 5: Create Launch Template → Key pair (login)

Desplegar lista → Don't include in launch template.



Paso 6: Create Launch Template → Network settings

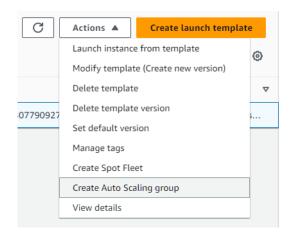
Security groups → Web Security Group



Tarea 4: Crear un Auto Scaling Group

En esta tarea, se utiliza la plantilla de lanzamiento para crear un Auto Scaling group.

Paso 1: Launch Templates → lab-app-launch-template → Actions → Create Auto Scaling group



Paso 2: Create Auto Scaling group → Name

Auto Scaling group name = Lab Auto Scaling Group

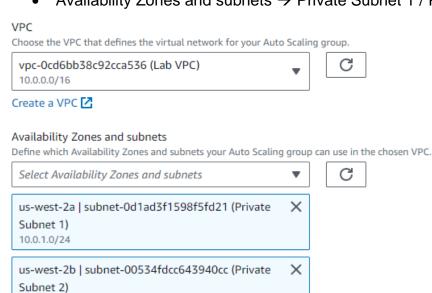
Name
Auto Scaling group name Enter a name to identify the group.
Lab Auto Scaling Group
Must be unique to this account in the current Region and no more than 255 characters

Paso 3: Create Auto Scaling group → Instance launch options → Network

VPC → Lab VCP

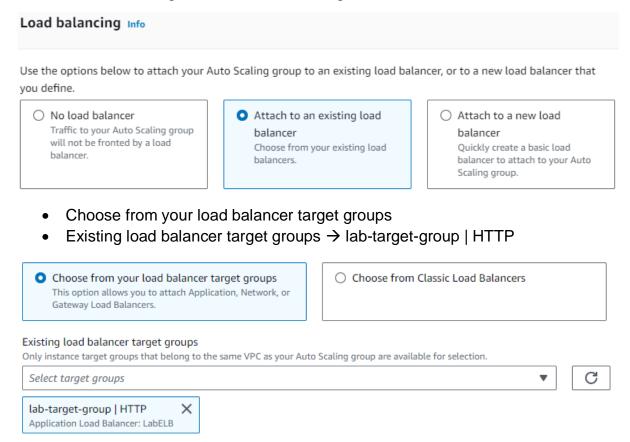
10.0.3.0/24

Availability Zones and subnets → Private Subnet 1 / Private Subnet 2.



Paso 4: Create Auto Scaling group → Configure advanced options

Load Balancing → Attach to an existing load balancer



Health checks → Health check type → Selectionar casilla "ELB".

Health checks

Health checks increase availability by replacing unhealthy instances. When you use multiple health checks, all are evaluated, and if at least one fails, instance replacement occurs.

EC2 health checks

Always enabled

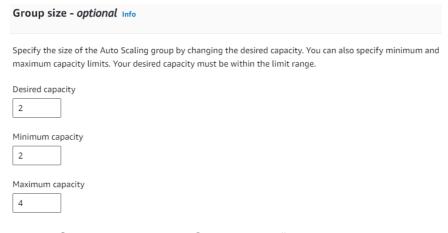
Additional health check types - optional Info

✓ Turn on Elastic Load Balancing health checks Recommended

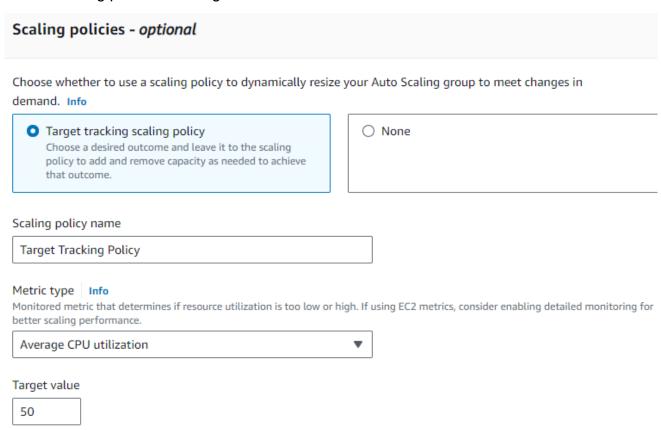
Elastic Load Balancing monitors whether instances are available to handle requests. When it reports an unhealthy instance, EC2 Auto Scaling can replace it on its next periodic check.

Paso 5: Create Auto Scaling group → Configure group size and scaling policies

Group size → Desired capacity = 2, Minimum capacity = 2, Maximum capacity = 4.



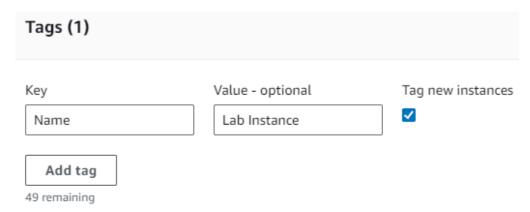
- Scaling policies → Selectionar "Target tracking scaling policy "
- Scaling policies → Metric type → Average CPU utilization
- Scaling policies → Target Value = 50



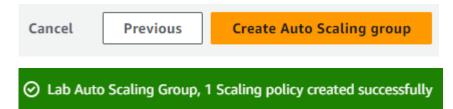
Este cambio indica a Auto Scaling Group que mantenga una utilización media de la CPU en todas las instancias del 50 por ciento. Auto Scaling agrega o elimina capacidad automáticamente según sea necesario para mantener la métrica en o cerca del valor objetivo especificado. Se ajusta a las fluctuaciones en la métrica debido a un patrón de carga fluctuante.

Paso 6: Create Auto Scaling group → Add tags → Add tag

- Key = Name
- Value = Lab Instance

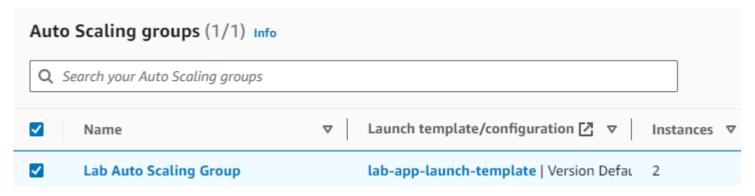


Paso 6: Create Auto Scaling group → Create



Estas opciones lanzan instancias EC2 en subredes privadas en ambas zonas de disponibilidad.

Su Auto Scaling Group muestra inicialmente un recuento de instancias de cero, pero se lanzarán nuevas instancias para alcanzar el recuento deseado de dos instancias.

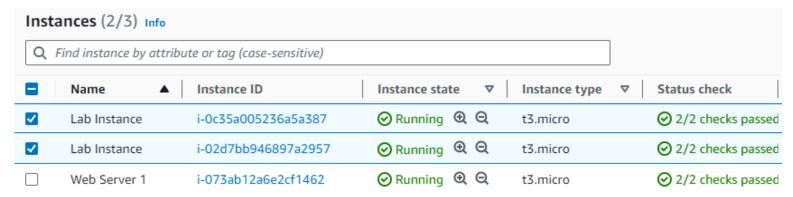


Tarea 5: Verificar el funcionamiento del balanceador de carga

En esta tarea, se verifica que el equilibrio de carga funciona correctamente.

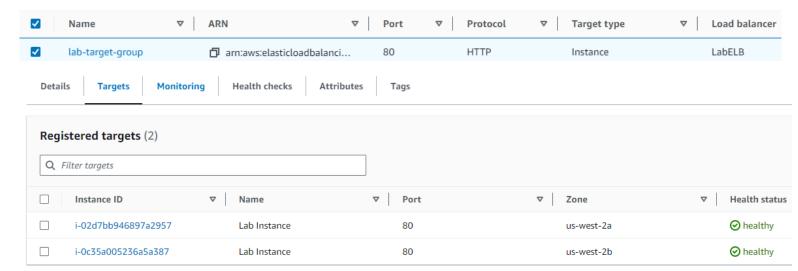
Paso 1: EC2 → Instances

• Se pueden ver disponibles dos instancias de nombre Lab Instance que fueron lanzadas por Auto Scaling.



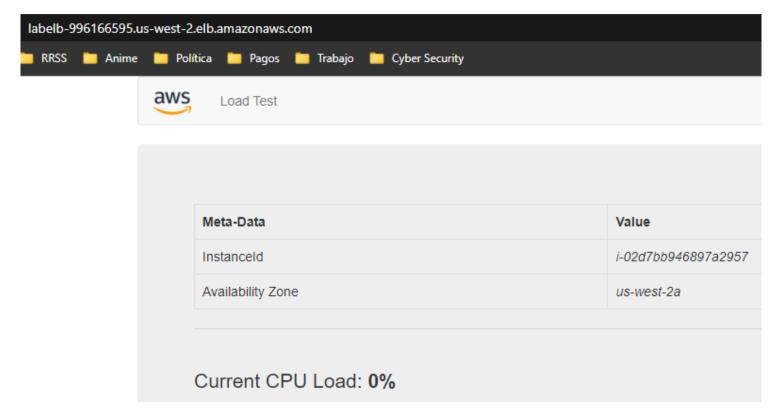
Paso 2: EC2 → Load Balancing → Target Groups → lab-target-group

- Registered targets → Aparecen dos Lab Instances
- Health Status → healthy
- healthy = Indica que una instancia ha superado la comprobación de salud del equilibrador de carga (Esta comprobación significa que el equilibrador de carga enviará tráfico a la instancia).



Paso 3: Pegar el DNS name copiado anteriormente en una nueva pestaña de navegador web.

• La Load Test Application debería aparecer en su navegador, lo que significa que el equilibrador de carga recibió la solicitud, la envió a una de las instancias de EC2 y, a continuación, devolvió el resultado.



Tarea 6: Probar el Auto Scaling Group

Ha creado un Auto Scaling Group con un mínimo de dos instancias y un máximo de cuatro instancias.

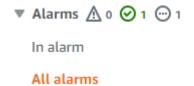
Actualmente, dos instancias están funcionando porque el tamaño mínimo es dos y el grupo no está bajo ninguna carga. Ahora aumentará la carga para que el autoescalado añada instancias adicionales.

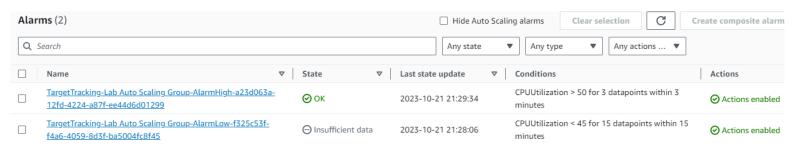
Paso 1: AWS Management Console → Search → CloudWatch



Paso 2: CloudWatch → Panel de navegación → Alarms → All Alarms

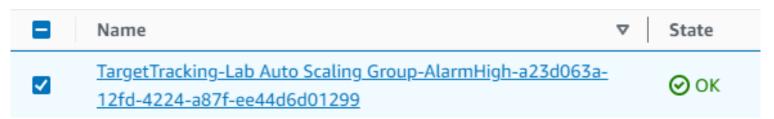
- Hay 2 alarmas desplegadas que fueron creadas automáticamente por el Auto Scaling Group.
- Estas alarmas mantienen automáticamente la carga media de la CPU cerca del 50 por ciento, mientras se mantienen dentro de la limitación de tener de 2 a 4 instancias.





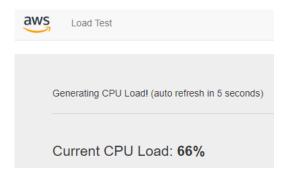
Paso 3: CloudWatch → Panel de navegación → Alarms → All Alarms → AlarmHigh

- State → OK
- OK = Indica que la alarma no ha sido iniciada.



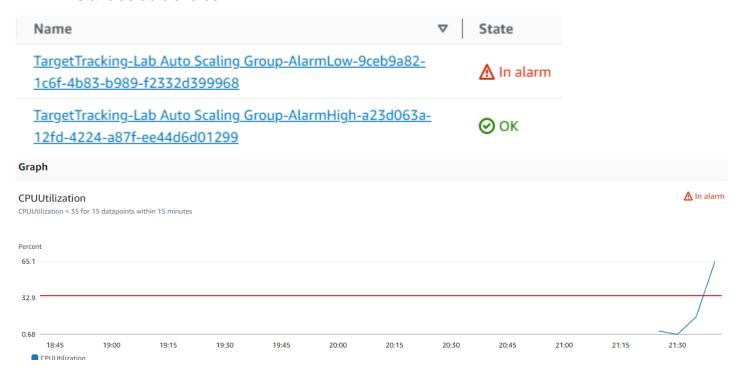
Paso 4: Ir al navegador que tiene la Load Test Application y seleccionar Load Test.

• Esto hace que la aplicación genere cargas elevadas. La página del navegador se actualiza automáticamente para que todas las instancias del grupo Auto Scaling generen cargas.



Paso 5: CloudWatch → Panel de navegación → Alarms → All Alarms

- AlarmLow → OK
- AlarmHigh → In Alarm
- Se puede ver el gráfico AlarmHigh indicando un porcentaje creciente de CPU. Una vez que cruza la línea del 50% durante más de 3 minutos, se inicia el escalado automático para añadir instancias adicionales.



Paso 6: EC2 → Instances

- Se pueden ver más de dos instancias de nombre Lab Instance en ejecución.
- Auto Scaling Group lanzó nuevas instancias en respuesta a la alarma.

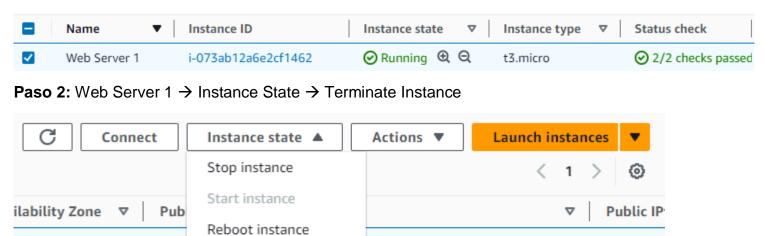
	Name 🔺	Instance ID	Instance state	Instance type ▼	Status check
~	Lab Instance	i-015ebcdb763c03567	⊗ Running ② ○	t3.micro	Initializing
~	Lab Instance	i-0c35a005236a5a387	⊘ Running ② ○	t3.micro	⊘ 2/2 checks passed
~	Lab Instance	i-02d7bb946897a2957	⊘ Running ⊕ ⊖	t3.micro	⊘ 2/2 checks passed
	Web Server 1	i-073ab12a6e2cf1462	⊘ Running ⊕ ⊖	t3.micro	2/2 checks passed

Tarea 7: Terminar la instancia Web Server 1

En esta tarea, se finaliza la instancia Web Server1.

Esta instancia se utilizó para crear la AMI que utilizó su Auto Scaling Group, pero ya no es necesaria.

Paso 1: EC2 → Instances → Web Server 1



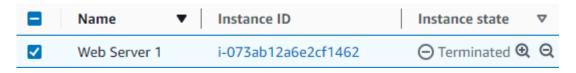
54.186.1

⊘ Successfully terminated i-073ab12a6e2cf1462

vest-2b

vest-2b

unct 2h



Hibernate instance

Terminate instance

Laboratorio Completado

